



Département de Génie Informatique

Mémoire de Fin d'études - Trading Algorithmique utilisant les Réseaux de Neurones - Premier Rapport

Etudiants

Yiğit YUMUŞ yigit.yumus@ogr.gsu.edu.tr

1^{er} mars 2024

Encadrants

Günce K. ORMAN

Table des matières

1	Introduction	3
2	Revue de Littérature	4
2.1	Application des calculs évolutifs pour la découverte de règles dans le trading algorithmique d'actions : Une revue de littérature [Hu et al., 2015]	4
2.1.1	Dévoiler le paysage : Une revue systématique	4
2.1.2	Mettre en lumière les résultats clés :	4
2.1.3	Une feuille de route pour des explorations futures :	5
2.1.4	Conclusion :	5
2.2	Une stratégie de trading algorithmique haute fréquence pour les cryptomonnaies [Vo & Yost-Bremm, 2020].	6
2.2.1	La puissance des indicateurs et de l'apprentissage automatique : . . .	6
2.2.2	Tests rigoureux : Validation du moteur HFT	6
2.2.3	Contributions et orientations futures :	7
2.2.4	Conclusion :	7
2.3	Trading algorithmique et information [Hendershott & Riordan, 2011].	8
2.3.1	Au-delà de l'automatisation : Activité stratégique et informée des algorithmes	8
2.3.2	De consommateurs opportunistes à chercheurs de valeur : Double rôle de l'AT dans la gestion de la liquidité	8
2.3.3	Vers une efficacité des prix : Contribution de l'AT à un marché plus juste	9
2.3.4	Au-delà des chiffres : Mises en garde et considérations	9
2.3.5	Conclusion :	9
2.4	Utilisation des réseaux neuronaux artificiels et des algorithmes génétiques pour construire un modèle de trading algorithmique pour la spéculation intra-journalière sur le marché des changes [Evans et al., 2013].	10
2.4.1	Tirer parti de la reconnaissance de motifs des ANN :	10
2.4.2	Évolution pour vaincre : Le rôle des algorithmes génétiques	10
2.5	Validation par des tests rigoureux :	11
2.5.1	Au-delà des chiffres : Implications et orientations futures :	11
2.5.2	Conclusion :	11
2.6	Surpasser les systèmes de trading algorithmique basés sur l'apprentissage par renforcement : une approche supervisée sur le marché des cryptomonnaies [Felizardo et al., 2022].	12
2.6.1	L'apprentissage supervisé prend les commandes :	12
2.6.2	Une symphonie de caractéristiques :	12
2.6.3	Face-à-face : Supervisé vs RL :	13
2.6.4	Au-delà des chiffres : Implications et orientations futures :	13

2.6.5	Conclusion :	13
3	Méthodologie et Technologies Utilisées	14
3.1	Collecte et Prétraitement des Données	14
3.1.1	Source de données	14
3.1.2	Prétraitement	14
3.2	Développement du Modèle	14
3.2.1	Architecture du modèle	14
3.2.2	Formation et Optimisation	14
3.3	Évaluation et Backtesting	14
3.3.1	Métriques de performance	14
3.3.2	Backtesting	14
3.4	Conclusion	15
4	Conception de Haut-Niveau	15
5	Calendrier de Travail	15

1 Introduction

L'évolution des marchés financiers a été accompagnée d'une montée en puissance du trading algorithmique. Ces dernières années, la quête de modèles de trading efficaces, adaptatifs et robustes a incité les chercheurs à explorer diverses méthodes computationnelles et techniques d'apprentissage automatique. Parmi ces méthodologies, l'informatique évolutive (EC), l'apprentissage par renforcement (RL) et l'apprentissage supervisé ont émergé comme des outils puissants pour découvrir et mettre en œuvre des règles de trading dans divers domaines financiers.

Cette revue de littérature vise à explorer l'application de l'informatique évolutive et des techniques d'apprentissage automatique dans le trading algorithmique à travers différents segments des marchés financiers. En se concentrant sur des études et avancées notables, cette revue navigue à travers les domaines des marchés boursiers, des cryptomonnaies, du forex et d'autres instruments financiers. En scrutant les méthodologies, les perspectives et les implications présentées dans les articles de recherche existants, cette revue s'efforce de fournir une compréhension complète des techniques de pointe actuellement employées dans le trading algorithmique.

Cette revue examine le rôle du trading algorithmique dans l'influence des processus de découverte des prix au sein d'indices boursiers spécifiques, dévoilant le comportement stratégique et l'impact de ces algorithmes sur la liquidité et la formation des prix. De plus, elle étudie la synergie entre les réseaux neuronaux artificiels, les algorithmes génétiques et leurs applications dans la construction de modèles de trading robustes pour la spéculation intra-journalière sur le forex.

En synthétisant et analysant ces diverses études, cette revue de littérature vise à fournir un panorama complet de l'application des techniques computationnelles dans le trading algorithmique à travers de multiples domaines financiers, mettant en lumière les tendances actuelles, les défis et les orientations futures dans ce domaine en constante évolution.

2 Revue de Littérature

2.1 Application des calculs évolutifs pour la découverte de règles dans le trading algorithmique d’actions : Une revue de littérature [Hu et al., 2015]

Alors que le trading algorithmique a gagné un intérêt significatif ces dernières années, la recherche de règles de trading robustes et pertinentes reste un défi crucial. Les techniques de calcul évolutif (CE), inspirées par la sélection naturelle et l’adaptation, ont émergé comme des outils prometteurs pour découvrir de telles règles, en particulier dans l’arène complexe et dynamique des marchés boursiers. Cet article, "Application des calculs évolutifs pour la découverte de règles dans le trading algorithmique d’actions : Une revue de littérature", plonge profondément dans l’état actuel de l’art de ce domaine passionnant.

2.1.1 Dévoiler le paysage : Une revue systématique

Les auteurs mènent une analyse approfondie de 51 articles pertinents publiés avant 2013, constituant la première investigation approfondie des techniques de CE appliquées à la découverte de règles dans le trading algorithmique. Ils classifient ces études selon trois méthodes analytiques :

- **Analyse fondamentale** : Axée sur des facteurs économiques et financiers tels que la santé de l’entreprise et les tendances sectorielles.
- **Analyse technique** : Utilisant des données historiques de prix et de volume pour identifier des modèles et prédire les mouvements futurs du marché.
- **Analyse combinée** : Combinant à la fois des approches fondamentales et techniques pour une perspective plus holistique.

De plus, la revue classe les techniques de CE utilisées en trois catégories :

- **Algorithmes évolutifs** : Utilisant une optimisation basée sur une population, où des solutions candidates prometteuses évoluent par sélection et mutation.
- **Intelligence de groupe** : Imitant le comportement collectif des essaims naturels (par exemple, les colonies de fourmis) pour optimiser les solutions grâce au partage d’informations et à la collaboration.
- **Techniques de CE hybrides** : Combinaison de différentes approches de CE pour des performances et une flexibilité accrues.

2.1.2 Mettre en lumière les résultats clés :

La revue dévoile plusieurs insights remarquables :

- **Dominance des AG et GP dans l’analyse technique** : Les algorithmes génétiques (AG) et la programmation génétique (GP) règnent en maîtres dans la découverte de règles de trading technique, probablement en raison de leur capacité à faire évoluer efficacement des stratégies de trading basées sur des modèles de données historiques.

- **Asymétrie des performances selon la tendance du marché :** De manière intéressante, alors que les modèles basés sur les CE brillent souvent en période de baisse, leurs performances ont tendance à faiblir pendant les périodes de hausse. Cette asymétrie pointe vers un biais potentiel envers les indicateurs baissiers et souligne le besoin de stratégies de création de règles plus équilibrées.
- **L'importance des coûts de transaction :** La revue souligne l'impact significatif des coûts de transaction sur la rentabilité du modèle. Une prise en compte minutieuse de ces frais lors du processus d'optimisation est cruciale pour garantir des règles de trading réalistes et pratiques.
- **Au-delà des aspects techniques :** Opportunités et défis : Bien que l'analyse technique règne en maître dans les études examinées, le manque de recherche sur l'analyse fondamentale et les approches combinées suggère un terrain fertile pour des explorations futures. De plus, l'intégration de la prédiction de tendances du marché et des stratégies de sélection de portefeuille dans les modèles basés sur les CE présente des avenues de recherche passionnantes.

2.1.3 Une feuille de route pour des explorations futures :

En éclairant les forces et les limites des recherches existantes, cette revue ouvre la voie à de nouveaux progrès dans la découverte de règles basées sur les CE pour le trading algorithmique. Certaines questions clés et directions de recherche potentielles mises en évidence par les auteurs incluent :

- Est-ce que les CE peuvent être efficacement appliqués à l'analyse fondamentale et aux approches combinées pour des insights diversifiés sur le marché ?
- Comment les modèles basés sur les CE peuvent-ils être exploités pour prédire avec précision les tendances du marché afin d'améliorer les stratégies de trading ?
- Est-ce qu'incorporer des techniques de sélection de portefeuille dans le processus d'optimisation peut conduire à des rendements ajustés au risque améliorés ?
- Comment intégrer les coûts de transaction de manière transparente dans le processus de découverte de règles pour une évaluation plus réaliste du modèle ?

2.1.4 Conclusion :

Cette revue approfondie met en lumière le potentiel prometteur des techniques de CE pour la découverte de règles dans le trading algorithmique. En mettant en évidence les succès et les lacunes des recherches existantes, les auteurs offrent une feuille de route précieuse pour de futurs progrès dans ce domaine dynamique. En adoptant l'innovation et en abordant les défis identifiés, les CE ont le potentiel de révolutionner la manière dont nous concevons et mettons en œuvre des stratégies de trading algorithmique, ouvrant la voie à des approches plus axées sur les données et adaptatives dans le monde toujours changeant des marchés financiers.

2.2 Une stratégie de trading algorithmique haute fréquence pour les cryptomonnaies [Vo & Yost-Bremm, 2020].

Les cryptomonnaies, illustrées par Bitcoin, ont captivé le monde financier par leur potentiel d'innovation perturbatrice et de rendements lucratifs. Cependant, leur nature volatile et en constante évolution demande des stratégies de trading agiles et sophistiquées. C'est là qu'intervient le trading algorithmique haute fréquence (HFT), une technique qui automatise les décisions d'achat et de vente rapides basées sur des algorithmes complexes analysant les données de marché.

Cet article aborde le défi de concevoir une stratégie HFT efficace spécifiquement adaptée à l'univers des cryptomonnaies. S'appuyant sur le cadre de recherche en science de la conception (DSR, Design Science Research), les auteurs présentent un artefact novateur : un algorithme de trading au niveau de la minute conçu pour Bitcoin. Ce système innovant exploite des données de six bourses de cryptomonnaies différentes, offrant une vision holistique des mouvements du marché à travers des plateformes diverses.

2.2.1 La puissance des indicateurs et de l'apprentissage automatique :

Le cœur de l'algorithme HFT réside dans ses capacités d'analyse de données et de prise de décision. Pour naviguer dans les courants volatils du marché des cryptomonnaies, les auteurs utilisent deux outils clés :

- **Indicateurs financiers** : Ces repères techniques, dérivés des données historiques de prix et de volume, fournissent des informations sur les tendances du marché et les opportunités potentielles. L'article ne mentionne pas explicitement les indicateurs spécifiques utilisés, mais il est probable qu'ils englobent des mesures telles que les bandes de Bollinger, l'indice de force relative (RSI) et la convergence/divergence des moyennes mobiles (MACD).
- **Apprentissage automatique (AA)** : L'algorithme d'apprentissage automatique choisi, dans ce cas, Random Forest, agit comme le cerveau de l'opération. En analysant les données du marché à travers le prisme des indicateurs choisis, l'algorithme identifie des modèles et prédit les mouvements potentiels des prix futurs. Ces informations guident ensuite les décisions de trading, automatisant les ordres d'achat et de vente à grande vitesse pour capitaliser sur les opportunités fugaces du marché.

2.2.2 Tests rigoureux : Validation du moteur HFT

L'article ne se contente pas de vanter les mérites théoriques de son algorithme HFT ; il teste rigoureusement son efficacité à travers deux méthodes distinctes :

- **Comparaison algorithmique** : Les auteurs confrontent leur stratégie HFT alimentée par Random Forest à un autre algorithme d'apprentissage automatique populaire. Cette confrontation tête-à-tête révèle la performance supérieure en moyenne de l'algorithme proposé, démontrant son avantage compétitif sur le marché du trading.

- **Performance hors échantillon :** Pour évaluer l'applicabilité réelle, les chercheurs testent l'algorithme HFT avec des données historiques du marché des changes (Forex). Cette approche simule comment la stratégie se comporterait dans un environnement de marché différent, fournissant des informations précieuses sur son potentiel d'application plus large.

2.2.3 Contributions et orientations futures :

L'article apporte des contributions précieuses au domaine émergent du HFT dans les marchés des cryptomonnaies. Il décrit un algorithme de trading clairement défini et testé, offrant un plan pratique pour les chercheurs et les praticiens. De plus, l'analyse des techniques de prétraitement des données et des considérations de sélection de modèle offre des orientations précieuses pour ceux qui élaborent leurs propres stratégies HFT.

En mettant en avant la performance prometteuse de leur algorithme HFT, les auteurs ouvrent des portes à de futures recherches et développements dans ce domaine passionnant. Les pistes potentielles pour des explorations futures incluent :

- **Élargir la couverture du marché :** Appliquer le cadre HFT à d'autres cryptomonnaies que Bitcoin pour évaluer sa généralisabilité et son adaptabilité.
- **Intégrer l'analyse fondamentale :** Compléter l'analyse des données avec des facteurs économiques et financiers réels pour construire des modèles de trading plus complets.
- **Optimiser les coûts de transaction :** Affiner l'algorithme pour minimiser l'impact des frais de transaction, un facteur significatif dans la rentabilité réelle.
- **Faire évoluer le modèle AA :** Explorer d'autres algorithmes d'apprentissage automatique ou ensembles pour potentiellement améliorer les performances de trading et s'adapter aux dynamiques changeantes du marché.

2.2.4 Conclusion :

"Une stratégie de trading algorithmique haute fréquence pour les cryptomonnaies" met en lumière les possibilités excitantes de tirer parti du HFT dans le domaine dynamique des cryptomonnaies. En présentant un algorithme de trading bien testé et efficace, les auteurs offrent des informations précieuses et ouvrent la voie à de futurs progrès dans ce domaine en constante évolution. Alors que le paysage des cryptomonnaies continue de mûrir, il sera fascinant de voir comment les stratégies HFT, alimentées par les avancées dans l'analyse de données et l'apprentissage automatique, façonneront l'avenir de cette frontière financière révolutionnaire.

2.3 Trading algorithmique et information [Hendershott & Riordan, 2011].

Cette recherche menée par Hendershott et Riordan explore le domaine en plein essor du trading algorithmique (AT) et son impact sur le processus de découverte des prix sur le marché boursier allemand. En se concentrant sur l'indice DAX 30 pendant janvier 2008, l'étude offre des insights précieux sur la manière dont les algorithmes AT naviguent sur le marché, façonnant la liquidité et influençant la formation des prix.

L'étude dévoile l'empreinte significative de l'AT sur le marché, révélant qu'il représente une part étonnante de 52 % de toute la demande de volume et 50 % de l'offre de volume. Cette domination signifie l'influence profonde qu'exerce l'AT sur la dynamique du marché, à la fois en recherchant et en fournissant de la liquidité.

2.3.1 Au-delà de l'automatisation : Activité stratégique et informée des algorithmes

La recherche dissipe l'idée que l'AT est une machine à ordres dénuée de réflexion. Au contraire, elle met l'accent sur la nature stratégique de ces algorithmes, soulignant leur capacité à surveiller le marché pour des informations clés

- **Détectives de liquidité** : Les algorithmes AT parcourent le marché, identifiant des sources de liquidité facilement disponibles et exploitant ces opportunités grâce à des ordres d'achat. Ce comportement aide à maintenir une activité de marché constante et facilite l'exécution des transactions.
- **Chasseurs de valeur** : Les yeux des algorithmes vont au-delà des seuls niveaux de liquidité. Ils analysent activement les mouvements de prix, recherchant des déviations potentielles par rapport à la valeur fondamentale. Cette fonction de "découverte des prix" permet des corrections sur le marché et favorise une tarification équitable des actifs.

2.3.2 De consommateurs opportunistes à chercheurs de valeur : Double rôle de l'AT dans la gestion de la liquidité

L'étude met également en lumière le comportement adaptatif de l'AT en ce qui concerne la liquidité. Elle met en avant deux scénarios distincts :

- **Consommateurs de liquidité** : Lorsque la liquidité est abondante et facilement disponible, les algorithmes AT en profitent en initiant des ordres d'achat. Cette "consommation de liquidité" contribue à la profondeur du marché et réduit la volatilité des prix.
- **Fournisseurs de liquidité** : À l'inverse, lorsque la liquidité devient rare et coûteuse, les algorithmes AT changent stratégiquement de rôle, agissant en tant que fournisseurs de liquidité en passant des ordres de vente. Ce comportement contribue à réguler la liquidité du marché, prévenant les perturbations potentielles causées par des opportunités de trading limitées.

2.3.3 Vers une efficacité des prix : Contribution de l'AT à un marché plus juste

En consommant et en fournissant stratégiquement de la liquidité, ainsi qu'en se concentrant sur un placement efficace des citations et la découverte des prix, les algorithmes AT contribuent de manière démontrable à l'efficacité du marché. Cela entraîne plusieurs résultats positifs :

- **Disparité des prix réduite** : L'activité de l'AT contribue à réduire l'écart entre les prix du marché actuels et leur valeur fondamentale sous-jacente, conduisant à une réflexion plus précise sur la vraie valeur d'un actif.
- **Amélioration de la diffusion de l'information sur le marché** : Les algorithmes AT agissent comme des machines de traitement de l'information, analysant de gros volumes de données de marché et les incorporant dans leurs décisions de trading. Ce traitement efficace de l'information peut améliorer le flux d'informations global sur le marché, permettant à tous les participants de prendre des décisions plus éclairées.
- **Approfondissement et résilience du marché renforcés** : Grâce à sa gestion active de la liquidité, l'AT renforce la capacité du marché à absorber de gros ordres de trading sans fluctuations de prix significatives. Cette augmentation de la profondeur contribue à une plus grande stabilité du marché et à une plus grande résilience face aux chocs externes.

2.3.4 Au-delà des chiffres : Mises en garde et considérations

Bien que l'étude présente une image positive du rôle de l'AT sur le marché, elle reconnaît également des limitations et des préoccupations potentielles :

- **Limites des données** : L'analyse est basée sur des données de 2008, précédant l'avènement du trading haute fréquence et d'autres techniques avancées de l'AT. Le paysage actuel du marché peut présenter des dynamiques et des défis différents.
- **Risques de manipulation du marché** : Bien que l'étude se concentre sur les aspects positifs de l'AT, il faut tenir compte du potentiel de manipulation grâce à un placement stratégique des ordres ou une asymétrie de l'information.
- **Réglementation et transparence** : À mesure que l'AT évolue, le besoin de cadres réglementaires appropriés et d'une transparence accrue au sein de l'écosystème du marché devient de plus en plus important.

2.3.5 Conclusion :

Cette recherche offre une perspective précieuse sur le monde complexe du trading algorithmique. En explorant son comportement stratégique, son impact sur la liquidité et sa contribution à la découverte des prix, l'étude dresse un tableau multifacette de l'influence de l'AT sur le marché. Tout en reconnaissant les risques et les limitations potentiels, la recherche met en lumière le rôle positif que peut jouer l'AT dans la promotion de l'efficacité

du marché et l'amélioration de la formation des prix. Alors que la technologie et les pratiques de trading continuent d'évoluer, de nouvelles recherches et des efforts réglementaires seront cruciaux pour garantir que l'AT contribue à un marché équitable et efficace pour tous les participants.

2.4 Utilisation des réseaux neuronaux artificiels et des algorithmes génétiques pour construire un modèle de trading algorithmique pour la spéculation intra-journalière sur le marché des changes [Evans et al., 2013].

La nature dynamique du marché des changes (forex) présente à la fois des opportunités séduisantes et des défis redoutables pour les investisseurs. Naviguer dans ce paysage volatil exige des méthodologies sophistiquées capables d'identifier des fenêtres fugaces de génération de bénéfices. Cet article d'Evans, Pappas et Xhafa propose une approche novatrice : utiliser la puissance synergique des réseaux neuronaux artificiels (ANN) et des algorithmes génétiques (AG) pour construire un modèle robuste pour la spéculation intra-journalière sur le forex.

2.4.1 Tirer parti de la reconnaissance de motifs des ANN :

Au cœur du modèle proposé se trouve un ANN, une structure computationnelle imitant les neurones interconnectés du cerveau humain. Ce prodige de l'apprentissage automatique excelle dans l'extraction de motifs et de relations cachées au sein de données complexes, le rendant idéalement adapté pour dénouer la toile complexe des mouvements de prix du forex. L'ANN dans ce cas ingère une gamme complète de données historiques, comprenant :

- **Taux de change historiques** : Analyser les tendances passées et les fluctuations de prix à travers différentes périodes de temps fournit un contexte crucial pour prédire le comportement futur.
- **Indicateurs techniques** : Ces métriques quantitatives, comme l'indice de force relative (RSI) et la convergence/divergence des moyennes mobiles (MACD), offrent des aperçus sur la dynamique du marché et les points de retournement potentiels.
- **Facteurs externes** : Selon la paire de devises choisie et les conditions du marché, des points de données supplémentaires comme les publications de nouvelles économiques ou les événements mondiaux pourraient être incorporés pour une analyse plus holistique.

L'ANN traite ensuite méticuleusement ces données, découvrant des relations et des motifs subtils qui pourraient échapper même aux traders expérimentés. Ce processus d'"apprentissage" donne au modèle le pouvoir de reconnaître des signaux subtils et de développer des perspectives prédictives sur les mouvements de prix futurs.

2.4.2 Évolution pour vaincre : Le rôle des algorithmes génétiques

Cependant, le parcours vers des performances optimales ne se termine pas avec l'ANN seul. Pour affiner davantage le modèle et assurer son efficacité dans des conditions de

marché en constante évolution, les chercheurs utilisent un AG, une technique inspirée par la nature qui imite les principes de l'évolution darwinienne. Imaginez les ANN comme des "organismes de trading" concurrents au sein d'un environnement simulé. L'AG sélectionne itérativement les ANN les plus rentables, leur permettant de "se reproduire" et de produire une progéniture potentiellement dotée de stratégies de trading encore supérieures. À travers ce processus de mutation et de sélection, l'AG affine les ANN, les façonnant progressivement en redoutables "chasseurs de forex" capables d'identifier les opportunités de trading les plus lucratives.

2.5 Validation par des tests rigoureux :

L'efficacité de cette approche combinée transcende les promesses théoriques. Les chercheurs soumettent le modèle à des tests réels rigoureux en utilisant des données historiques du forex sur une période définie. Les résultats ? Encourageants, en effet. Le modèle ANN-AG démontre une rentabilité statistiquement significative, surpassant les stratégies de trading de référence en termes de rendement moyen et de performance ajustée au risque.

2.5.1 Au-delà des chiffres : Implications et orientations futures :

Cette recherche apporte une contribution précieuse au domaine émergent du trading quantitatif sur le forex. Au-delà des chiffres de performance louables, l'étude révèle plusieurs enseignements clés :

- **Les données comme fondement** : Le succès du modèle repose sur la qualité et la profondeur des données historiques qu'il reçoit. L'accès à des ensembles de données complets et fiables est crucial pour entraîner l'ANN et assurer sa précision prédictive.
- **Adaptation continue** : La nature dynamique des marchés forex nécessite des modèles adaptatifs. Les AG fournissent un outil puissant pour affiner constamment la stratégie de trading et garantir son efficacité dans des conditions de marché en perpétuelle évolution.
- **Au-delà des indicateurs techniques** : Bien que l'étude se concentre sur les indicateurs techniques, l'intégration de l'analyse fondamentale, tels que les indicateurs économiques et les événements géopolitiques, pourrait encore améliorer la performance et l'adaptabilité du modèle.

2.5.2 Conclusion :

Le travail d'Evans, Pappas et Xhafa ouvre la voie à l'application de techniques computationnelles avancées telles que les ANN et les AG dans le domaine exigeant du trading intra-journalier sur le forex. Leur modèle réussi démontre le potentiel de ces outils pour identifier des opportunités lucratives et naviguer dans les complexités de ce marché en constante évolution. Bien que des recherches et des améliorations supplémentaires soient nécessaires, cette étude offre une vision convaincante de l'avenir du trading quantitatif

dans le domaine du forex, où l'intelligence artificielle et l'ingéniosité humaine unissent leurs forces pour conquérir le labyrinthe insaisissable des mouvements de devises.

2.6 Surpasser les systèmes de trading algorithmique basés sur l'apprentissage par renforcement : une approche supervisée sur le marché des cryptomonnaies [Felizardo et al., 2022].

Le monde volatile et dynamique des cryptomonnaies recèle un immense potentiel de profit, mais naviguer dans ses eaux agitées nécessite des stratégies de trading robustes et adaptables. Dans ce domaine, l'apprentissage par renforcement (RL) a émergé comme une approche prometteuse, permettant aux algorithmes d'apprendre par essais et erreurs.

2.6.1 L'apprentissage supervisé prend les commandes :

Contrairement au RL, qui apprend de manière autonome grâce à un processus d'exploration, l'apprentissage supervisé tire parti de données facilement disponibles et de connaissances d'experts. Felizardo et al. créent un modèle sophistiqué, judicieusement nommé RSLSTM-A, utilisant un classificateur de séries temporelles basé sur l'architecture de réseau neuronal profond ResNet. Ce système puissant analyse méticuleusement les données historiques sur les prix et les volumes des cryptomonnaies, extrayant des motifs et des relations qui éclairent les décisions de trading futures.

2.6.2 Une symphonie de caractéristiques :

RSLSTM-A ne se contente pas de traiter les chiffres de manière aveugle. Il plonge plus profondément, extrayant une riche diversité de caractéristiques des données :

- **Indicateurs techniques** : Des mesures traditionnelles comme le RSI et le MACD aux complexes Bandes de Bollinger et Ichimoku, ces indicateurs offrent des aperçus sur la dynamique du marché, les tendances et les points de retournement potentiels.
- **Analyse de sentiment** : RSLSTM-A exploite la puissance du Traitement du Langage Naturel (NLP), analysant les articles de presse, les mentions sur les réseaux sociaux et d'autres sources textuelles pour évaluer le sentiment du public et son impact potentiel sur les prix des cryptomonnaies.
- **Facteurs fondamentaux** : Les publications de nouvelles économiques, les politiques gouvernementales et les événements mondiaux peuvent tous jouer un rôle dans les mouvements du marché. RSLSTM-A intègre ces facteurs pour saisir le tableau complet et prendre des décisions de trading éclairées.

En combinant ces caractéristiques diverses, RSLSTM-A peint un tableau complet du paysage des cryptomonnaies, lui permettant de prédire avec une précision remarquable les mouvements futurs des prix.

2.6.3 Face-à-face : Supervisé vs RL :

Les chercheurs ne se contentent pas de promesses théoriques. Ils confrontent RSLSTM-A à deux algorithmes RL performants dans un test rigoureux utilisant des données réelles sur les cryptomonnaies. Les résultats sont clairs : RSLSTM-A offre des performances supérieures, obtenant des rendements nettement plus élevés et démontrant une plus grande stabilité même dans des conditions de marché très volatiles.

2.6.4 Au-delà des chiffres : Implications et orientations futures :

Cette recherche transcende la simple performance qui bat les références. Elle met en lumière le potentiel de l'apprentissage supervisé dans le domaine volatile du trading de cryptomonnaies :

- **Les données sont le moteur :** Le succès de RSLSTM-A repose sur la qualité et la diversité des données qu'il ingère. L'accès à des données historiques complètes, aux flux de marché en temps réel et aux sources d'actualités pertinentes est crucial pour son efficacité.
- **La connaissance humaine rencontre la puissance des machines :** L'apprentissage supervisé permet aux chercheurs d'injecter des connaissances et des insights d'experts dans le modèle, lui permettant de saisir les nuances du marché que les approches purement basées sur les données pourraient manquer.
- **L'adaptabilité compte :** Les cryptomonnaies sont connues pour leur nature imprévisible. La capacité de RSLSTM-A à apprendre et s'adapter continuellement aux nouvelles données en fait un outil adapté pour naviguer dans cet environnement dynamique.

2.6.5 Conclusion :

Le travail novateur de Felizardo et al. remet en question la domination du RL dans le trading de cryptomonnaies. En mettant en avant la puissance de l'apprentissage supervisé, ils offrent une alternative convaincante pour naviguer dans les courants imprévisibles de ce marché passionnant. Bien que des recherches et des optimisations supplémentaires soient nécessaires, cette étude ouvre des portes passionnantes pour exploiter l'apprentissage supervisé et les réseaux neuronaux profonds afin de conquérir la frontière des cryptomonnaies, transformant le trading algorithmique avec une nouvelle finesse et une adaptabilité retrouvée.

3 Méthodologie et Technologies Utilisées

3.1 Collecte et Prétraitement des Données

3.1.1 Source de données

Les données historiques OHLCV (Open, High, Low, Close, Volume) seront récupérées à partir de l'API Binance.

3.1.2 Prétraitement

Les données collectées subiront plusieurs étapes de prétraitement :

- Traitement des valeurs manquantes (imputation ou suppression)
- Normalisation ou standardisation
- Ingénierie des caractéristiques (indicateurs techniques)

3.2 Développement du Modèle

3.2.1 Architecture du modèle

Un réseau LSTM sera implémenté en utilisant des bibliothèques Python comme TensorFlow, Keras ou PyTorch. L'architecture comprendra :

- Couche d'entrée : reçoit les données OHLCV prétraitées et potentiellement des caractéristiques supplémentaires.
- Couches LSTM cachées : capturent les dépendances temporelles et apprennent des modèles dans les séries temporelles.
- Couche de sortie : prédit le futur mouvement des prix.

3.2.2 Formation et Optimisation

Le modèle sera entraîné sur une partie des données historiques en minimisant une fonction de perte et en utilisant des techniques de régularisation.

3.3 Évaluation et Backtesting

3.3.1 Métriques de performance

Les performances du modèle seront évaluées à l'aide de métriques :

- Rendement cumulé
- Ratio de Sharpe
- Retrait maximal

3.3.2 Backtesting

Le modèle sera testé sur une autre partie des données historiques pour simuler les performances réelles.

3.4 Conclusion

Ce rapport présente une méthodologie de trading algorithmique utilisant des réseaux LSTM pour prédire les prix des contrats à terme sur les crypto-monnaies. Des recherches et des tests supplémentaires sont nécessaires avant une implémentation réelle.

4 Conception de Haut-Niveau

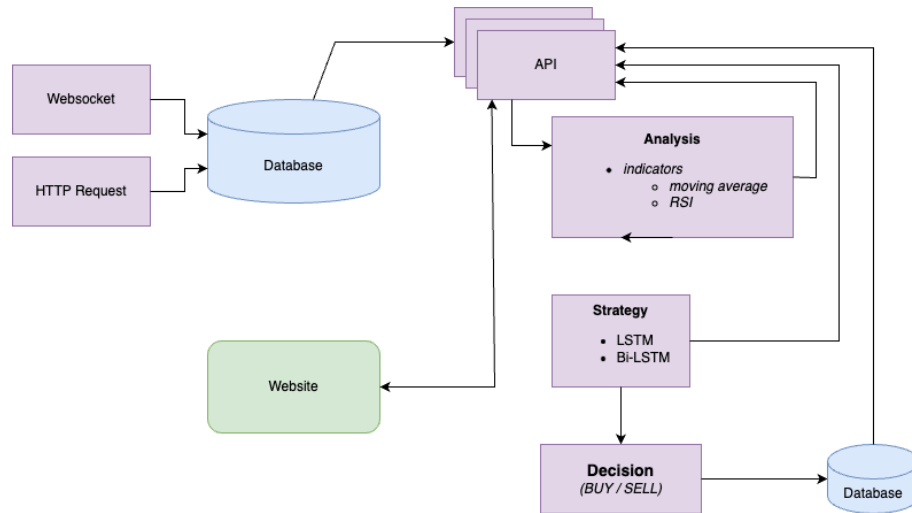


FIGURE 1 – Conception de système de haut niveau

5 Calendrier de Travail

Semaine 1-2 : Configuration du projet et acquisition de données

- Définir les objectifs et la portée du projet.
- Mettre en place l'environnement de développement (bibliothèques Python, structures de données).
- Rechercher et établir une connexion à l'API Binance pour la récupération des données.
- Explorer et documenter les données disponibles (OHLCV, caractéristiques supplémentaires).

Semaine 3-4 : Conception et test du système

- Concevoir l'architecture globale du système (pipeline de données, entraînement du modèle, évaluation).
- Mettre en œuvre les étapes de prétraitement des données (nettoyage, normalisation, ingénierie des caractéristiques).
- Développer des outils de visualisation des données pour analyser et comprendre les données historiques des prix.
- Effectuer les premiers tests unitaires des composants individuels du système.

Semaine 5-6 : Conception du modèle et développement initial

- Rechercher et choisir une architecture de réseau LSTM spécifique (nombre de couches, neurones).
- Concevoir le pipeline d'entraînement du modèle, y compris la sélection de la fonction de perte et de l'optimiseur.
- Mettre en œuvre l'architecture du modèle LSTM en utilisant les bibliothèques choisies (TensorFlow, Keras, etc.).
- Effectuer les premiers essais d'entraînement sur une petite partie des données pour évaluer la faisabilité.

Semaine 7-8 : Formation et optimisation du modèle

- Mettre en œuvre des techniques d'optimisation des hyperparamètres (recherche par grille, recherche aléatoire) pour optimiser les performances du modèle.
- Former le modèle sur une plus grande partie des données historiques, en surveillant la progression de la formation et la réduction des pertes.
- Évaluer les performances du modèle à l'aide de métriques choisies (rendement cumulé, ratio de Sharpe, drawdown).
- Analyser les résultats et identifier les domaines potentiels d'amélioration.

Semaine 9-10 : Backtesting et améliorations

- Développer un cadre de backtesting pour simuler les décisions de trading en fonction des prédictions du modèle.
- Effectuer un backtesting sur une partie distincte des données historiques non utilisées pour l'entraînement.
- Analyser les résultats du backtesting pour évaluer la robustesse du modèle et l'exposition au risque.
- Affiner et améliorer le modèle en fonction des résultats du backtesting et de l'évaluation des performances.

Semaine 11-12 : Documentation et finalisation

- Créer une documentation complète de l'ensemble du projet, comprenant la méthodologie, le code et les résultats.
- Préparer une présentation finale résumant les objectifs du projet, l'approche et les principales conclusions.
- Affiner et finaliser le projet en fonction des commentaires et des orientations futures potentielles.

Références

- [Evans et al., 2013] Evans, C., Pappas, K., & Xhafa, F. (2013). Utilizing artificial neural networks and genetic algorithms to build an algo-trading model for intra-day foreign exchange speculation. *Mathematical and Computer Modelling*, 58(5-6), 1249–1266.
- [Felizardo et al., 2022] Felizardo, L. K., Lima Paiva, F. C., de Vita Graves, C., Matsumoto, E. Y., Costa, A. H. R., Del-Moral-Hernandez, E., & Brandimarte, P. (2022). Outperforming algorithmic trading reinforcement learning systems : A supervised approach to the cryptocurrency market. *Expert Systems with Applications*, 202, 117259.
- [Hendershott & Riordan, 2011] Hendershott, T. & Riordan, R. (2011). Algorithmic trading and information. [Unpublished manuscript].
- [Hu et al., 2015] Hu, Y., Liu, K., Zhang, X., Su, L., Ngai, E. W. T., & Liu, M. (2015). Application of evolutionary computation for rule discovery in stock algorithmic trading : A literature review. *Applied Soft Computing*, 36, 534–551.
- [Vo & Yost-Bremm, 2020] Vo, A. & Yost-Bremm, C. (2020). A high-frequency algorithmic trading strategy for cryptocurrency. *Journal of Computer Information Systems*, 60(6), 555–568.